Rapport projet TLNL

Leader : Adrien ZABBAN
Follower : Yanis LABEYRIE

05 novembre 2023

1 Introduction

Le but de ce projet est de coder un modèle de langage basé sur un réseau de neurones multi-couches. Ce modèle de langage devra permettre de prédire le mot suivant à partir d'un contexte, qui est un ensemble de mots précédant le mot à prédire.

Pour faire cela, on utilise des embeddings. Le principe est d'associer à chaque mot un vecteur dans un espace latent de telle sorte que deux mots similaires (en termes de sens) aient des vecteurs proches (avec une distance euclidienne), et deux mots totalement différents soient très loin. Cela permet de projeter les mots dans un espace latent pour pouvoir travailler plus efficacement sur ces mots. On note e la dimension de cet espace.

Dans un premier temps, on utilisera les embeddings des mots appris par l'algorithme Word2Vec [1] (modèle nommé $FROZEN$). Par la suite, nous tenterons d'améliorer le modèle en lui permettant d'apprendre ses propres embeddings à partir d'embeddings aléatoires (modèle nommé $SCRATCH$), ou directement les embeddings appris de Word2Vec (modèle nommé $ADAPT$).

2 Modèle *FROZEN*

Nous avons implémenté le perceptron multi-couches comme modèle de langage de base. Celui-ci est composé d'une couche d'entrée qui prend un vecteur de dimension $k \times e$ représentant les embeddings de k mots concaténés. Une couche de neurones cachée dont nous avons choisi de faire varier le nombre de neurones noté h, suivie d'une fonction ReLU [2]. Puis une deuxième couche de neurones suivie d'un softmax retournant un vecteur de taille V, le nombre de mots appris. La Figure 1 représente ce modèle.

2.1 Formalisme mathématiques

En notant, $W \in \mathcal{M}_{k\times e,h_1}(\mathbb{R})$, et $U \in \mathcal{M}_{h,V}(\mathbb{R})$ les matrices de poids, $(b_1, b_2) \in \mathbb{R}^h \times \mathbb{R}^V$ les biais, $X \in \mathbb{R}^{k\times e}$ le vecteur d'entrée, l'équation 1 donne la fonction de sortie $F(X) \in \mathbb{R}^V$ du modèle.

$$F(x) = softmax(U(ReLU(WX + b_1)) + b_2) \tag{1}$$

Après plusieurs essais, nous avons choisi de prendre : $k = 3$, $e = 100$, $h_1 = 256$. Et dans nos données d'entraînement, on avait un vocabulaire contenant :

$V = 2908$ mots distincts. Avec ces hyperparamètres, nous avons dans ce modèle 824412 paramètres apprenables.

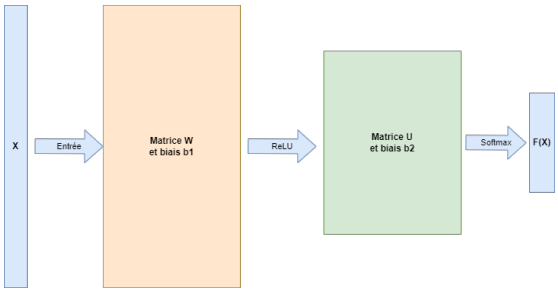

FIGURE 1 – Modèle : *FROZEN*

Pour entraîner ce modèle, nous avons comparé notre sortie au mot à prédire dans le format one-hot encoding [1], et nous appliquons le calcule de la fonction de coût : cross-entropy. On avons utilisé Adam [3] pour optimiser les paramètres avec un learning rate de 0.01 pour les 5 premières époques et 0.001 pour les suivantes.

2.2 Métriques

Nous avons par ailleurs décidé d'évaluer ce réseau à l'aide de plusieurs métriques comme l'accuracy, la perplexité, le f_1-score et la métrique "top k" [2] (avec $k = 5$), voir [4].

2.3 Entraînement

Sur la Figure 2, on voit les courbes d'apprentissage. Les valeurs des métriques sur les données d'entraînement sont en bleue, sur les données de validation sont en orange.

On constate d'après les courbes que le modèle apprend très vite (les courbes atteignent un plateau en quasiment 2 epochs). Ceci est dû au fait que les embeddings du modèle sont déjà appris. On observe par ailleurs que le modèle n'overfit pas car il n'y a pas de décalage important entre les valeurs de métrique d'entraînement et de validation à la fin de l'entraînement. Le modèle se stabilise à la fin de l'entraînement avec les métriques de validation présentés dans la Table 1.

métriques	accuracy	top k	perplexité	f_1 score
modèle *FROZEN*	0.19	0.34	144	9.6e-4

TABLE 1 – Meilleures métriques de validation obtenues en fin d'apprentissage du modèle *FROZEN*.

1. Le format one-hot encoding est un encodage des indices en un vecteur d'une taille du nombre d'indice possible tel que ce vecteur possède des 0 partout sauf à l'indice en question qui possède un 1.
2. La métrique "top-k" évalue un modèle en comptant combien de prédictions correctes il fait parmi les k premières prédictions les plus probables. Attention ici k n'est pas le nombre de mots dans le contexte !

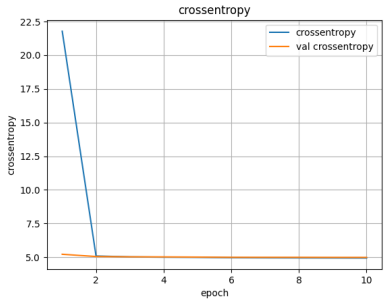

(a) Cross Entropy Loss (Lower is Better)

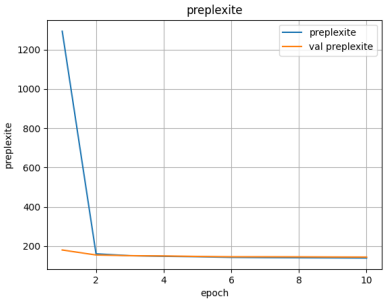

(b) perplexité (Lower is Better)

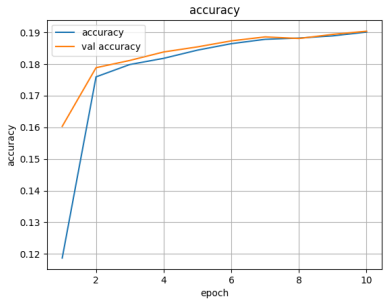

(c) Accuracy (Higher is Better)

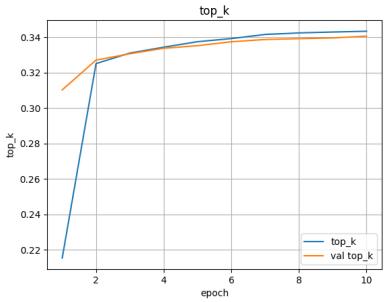

(d) top k, avec k=5 (Higher is Better)

FIGURE 2 – Entraînement du modèle *FROZEN*

3 Apprentissage automatique des embeddings par le modèle de langage : modèle *SCRATCH*

3.1 Description

Cette première piste que nous avons exploré consiste à dire que notre modèle d'embeddings pré-entraîné n'est pas forcément pertinent pour la tâche de prédiction du mot suivant d'une phrase. L'idée est donc de considérer que la matrice d'embeddings peut être apprise par le modèle de langage et que la matrice apprise sera plus pertinente qu'une matrice apprise séparément pour résoudre la tâche. On va donc considérer que les paramètres de la matrice sont des paramètres apprenables du modèle de langage et donc étendre jusqu'à eux l'algorithme de rétro-propagation du gradient.

3.2 Mise en œuvre

Il a fallu adapter un peu notre code car avant pour avoir l'embedding d'un mot i, nous avions utilisé $E[i]$, où $E \in \mathcal{M}_{V,e}(\mathbb{R})$ est la matrice d'embedding. Cependant, cette opération n'est pas dérivable, il a donc fallu transformer le mot i en un vecteur $x \in \mathbb{R}^V$ one-hot, et faire $x \times E$ pour obtenir l'embedding du mots i, qui cette fois-ci, est une opération dérivable. Une fois cette adaptation faite, on a rajouté cette opération dans notre modèle et nous obtenons donc un nouveau modèle illustré par la Figure 3, et donné par l'équation 2.

$$F(x) = softmax(U(ReLU(W\tilde{X} + b_1)) + b_2) \tag{2}$$

où $\tilde{X} = flatten(XE)$ [3] et $X \in \mathcal{M}_{k,V}(\mathbb{R})$.

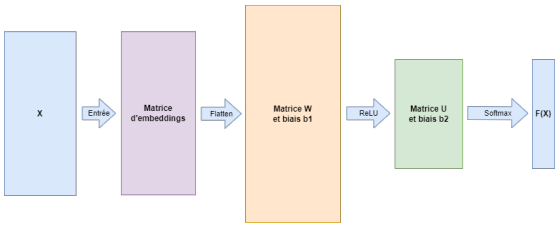

FIGURE 3 – Modèle : *SCRATCH* avec l'apprentissage des embeddings

3.3 Entraînement

On remarque, sur la Figure 4, tout d'abord que l'apprentissage à la fois du modèle et des embeddings est plus long car l'ensemble (modèle + matrice d'embedding) possède un plus grand nombre de paramètres (1115212 contre 824412 pour le modèle *FROZEN*) qui nécessitent donc plus d'époques que *FROZEN* pour être actualisés.

On obtient en terme de métriques de validation, des résultats semblables au modèle précédent. Cela s'explique par le fait que, bien qu'on apprenne par rétropropagation les embeddings et que donc on s'attend à une meilleure qualité de résultat, cela est compensé par le fait que l'apprentissage se fait à partir de 0 et l'on commence donc l'apprentissage avec des résultats aléatoires.

A la fin de l'apprentissage, nous obtenons les métriques de validation suivantes, comme on peut le voir dans la Table 2.

modèle	accuracy	top k	perplexité	f_1 score
FROZEN	0.19	0.34	144	9.6e-4
SCRATCH	0.195	0.333	280.37	1.27e-3

TABLE 2 – Meilleures métriques de validation obtenues en fin d'apprentissage des modèles *FROZEN* et *SCRATCH*.

4 Apprentissage des embeddings à partir de l'algorithme Word2Vec : modèle *ADAPT*.

4.1 Description

Dans cette partie, nous allons tenter d'améliorer la performance du modèle et surtout la vitesse d'apprentissage. Au lieu, d'initialiser la matrice d'embedding

3. flatten est l'oppération consistant à prendre une matrice est le transformer en vecteur en concaténant toutes les lignes. Cette oppération se généralise avec des tenseurs.

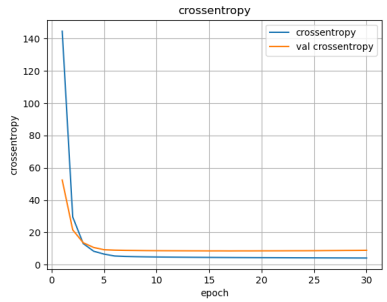

(a) Cross Entropy Loss (Lower is Better)

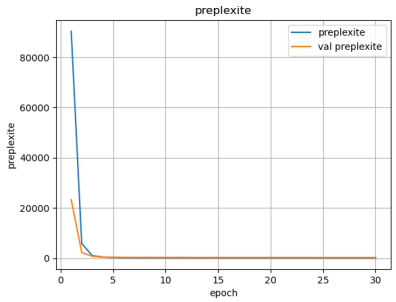

(b) perplexité (Lower is Better)

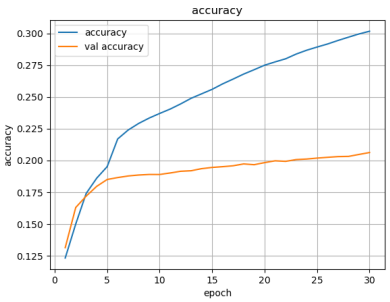

(c) Accuracy (Higher is Better)

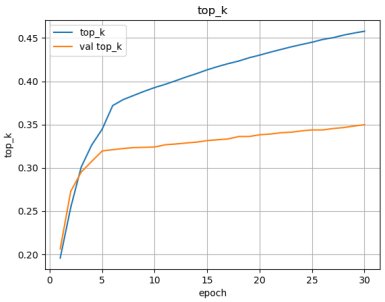

(d) top k, avec k=5 (Higher is Better)

FIGURE 4 – Entraînement du modèle *SCRATCH*

aléatoirement comme dans la partie précédente, nous allons initialiser cette matrice à partir des embeddings déjà appris avec l'algorithme Word2Vec. En procédant comme cela, nous allons pouvoir continuer d'apprendre ces embeddings pour coller au mieux à notre tâche de prédiction.

4.2 Mise en œuvre

La mise en œuvre de cette partie n'a pas été très compliquée à implémenter car le modèle est le même que celui de *SCRATCH*, voir Figure 3. Il nous a donc suffit de récupérer la matrice d'embedding apprise et de la copier dans le modèle lors de son initialisation.

4.3 Entraînement

On constate immédiatement, avec la Figure 5, que l'apprentissage est bien plus rapide dans le cas où on initialise les embeddings avec Word2Vec par rapport au cas où on les initialise aléatoirement. Cela s'explique par le fait que contrairement au modèle précédent, le modèle a déjà des embeddings valides aux début de l'apprentissage qu'il peut par la suite perfectionner.

Notre hypothèse était que initialiser les embeddings avec Word2Vec puis les modifier au cours de l'apprentissage permettrait d'obtenir de meilleures performances que celles du modèle où les embeddings sont gelés pendant l'apprentissage.

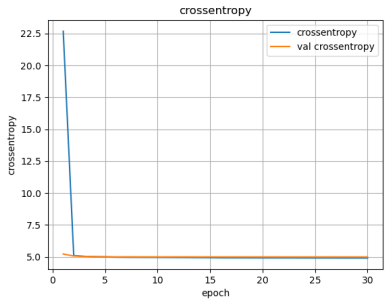

(a) Cross Entropy Loss (Lower is Better)

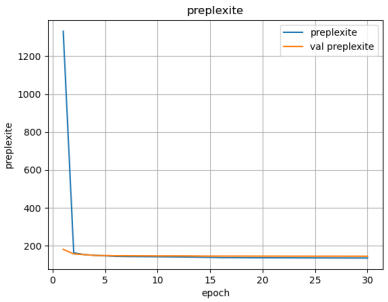

(b) perplexité (Lower is Better)

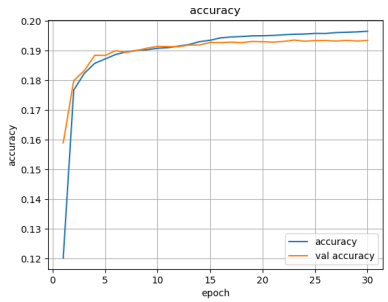

(c) Accuracy (Higher is Better)

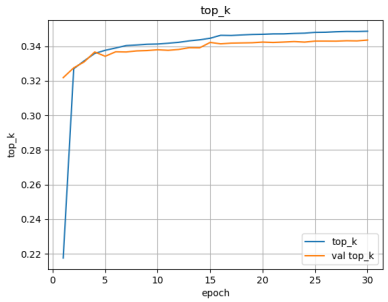

(d) top k, avec k=5 (Higher is Better)

FIGURE 5 – Entraînement du modèle *ADAPT*

5 Résultats

5.1 Performance

Après avoir entraîné ces trois modèles et pris les poids qui minimisent la loss de validation, nous avons ensuite passé ces modèles dans une base de données de test [4]. La Table 3 présente les résultats des modèles sur différentes métriques. On voit que les 3 modèles ont une accuracy et une métrique top k similaires. Cependant, le modèle *SCRATCH* est très mauvais sur la Cross Entropy et la perplexité (par rapport aux autres modèles). Il est aussi étonnant de constater que les modèles *FROZEN* et *ADAPT* ont des résultats similaires. Cela signifie que les embeddings appris par Word2Vec correspondent à cette tâche. Dans ce cas, les embeddings obtenus avec Word2Vec ont été appris sur le même corpus que l'entraînement des modèles. Nous pensons que si les embeddings avaient été appris sur un autre corpus, le modèle *ADAPT* aurait pu se différencier par rapport au modèle *FROZEN*.

5.2 Temps d'entraînement

Il peut aussi être intéressant de regarder le temps d'entraînement des différents modèles, voir Table 4. Ces modèles ont été entraînés sur un Windows 11

4. La base de données est bien sûr disjointe de celles de l'entraînement et de validation, mais toujours tirée du corpus du *Comte de Monté-Cristo* d'Alexandre Dumas.

modèles	Cross Entropy	accuracy	top k	f_1 score	perplexité
FROZEN	4.89	0.20	0.35	$9.42e-4$	131
SCRATCH	8.05	0.20	0.35	$1.16e-3$	247
ADAPT	4.90	0.20	0.35	$8.86e-4$	130

TABLE 3 – Résultat des différents modèles sur la base de données de teste.

avec un intel i7 de 12ème génération et une carte graphique : Nvidia RTX 3050 modèle ordinateur portable. On remarque sans surprise que l'entraînement le plus rapide est celui de *FROZEN* car c'est le modèle qui a le moins de paramètres. Il est très intéressant de voir que le modèle *ADAPT* s'entraîne beaucoup plus vite que le modèle *SCRATCH*, alors que le nombre de paramètres est le même. Notre hypothèse est que les poids de la matrice d'embeddings étant déja pertinents, peut-être que lors de la rétro-propagation certains gradients valent dès le début 0 et ne sont donc pas propagés, ce qui fait que la rétro-propagation prend moins de temps. En comparant les résultats des modèles et leurs temps d'entraînement, on peut voir qu'il n'est pas rentable d'entraîner un modèle comme celui de *SCRATCH*, si l'on a déjà une partie pré-entraînée car cela prend beaucoup de temps et que l'on des performances plus faibles.

modèles	*FROZEN*	*SCRATCH*	*ADAPT*
temps (en s)	360	1001	460
nombre de paramètres	800k	11M	11M

TABLE 4 – Comparaison du temps d'entraînement des différents modèles sur 10 epochs et nombre de paramètres apprenables des modèles.

5.3 Génération de texte des modèles

Après les entraînements des modèles, nous avons généré du texte avec les modèles à partir d'une entrée (input). Nous avons choisi arbitrairement un input qui est : *le vieillard fit un* car il fait partie du corpus de données d'entraînement. Nous avons ensuite généré les 10 mots suivants grâce aux modèles. La Table 5 représente les résultats obtenues.

modèles	génération
FROZEN	le vieillard fit un ,,,,,,,,,
SCRATCH	le vieillard fit un certains,,,,,,,,
ADAPT	le vieillard fit un ,,,,,,,,,

TABLE 5 – Résultat des générations de 10 mots des modèles à partir de : *le vieillard fit un.*

On constate que les mots suivants prédits par notre modèle sont peu pertinents et que surtout le modèle renvoie plusieurs fois le même mot à la suite, ici le mot ','. Ceci peut s'interpréter comme un phénomène de *mode collapse*, c'est à dire que le modèle présente peu de variété dans ses sorties. En effet le mot virgule étant très fréquent dans le corpus d'entraînement, il est normal qu'un modèle peu performant ne parvienne à générer que ce mot là.

Le problème vient de la façon dont on choisi le mot à générer à chaque étapes : on prend le mot m^* tel que $m^* = \text{argmax}_{m \in V} f(X)_m$, où f représente le modèles choisie et $f(X)_m$ est la probabilité du mot m connaissant le contexte X. Pour tenter de régler ce problème, à chaque étape, on prend les 5 mots qui sont les plus prédits (i.e. les 5 mots qui maximine $f(X)_m$), et l'on choisi de prendre un de ces 5 mots avec la loi de probailité : $P(m_i|X) = \alpha f(X)_{m_i}$, où $\alpha = 1/\sum_{i=1}^{5} f(X)_{m_i}$. On rajoute aussi une *température* $t \in]0, 1]$ à la fonction softmax dans les équations 1 et 2, décrite par la formule 3. Cela permet de rendre la distribution $f(X)$ plus homogènes et donc de générer un mot m différent que m^*.

$$\text{softmax}(X, t)_i = \frac{e^{X_i/t}}{\sum_j e^{X_j/t}} \tag{3}$$

On a donc ensuite fait de nouvelles générations de textes avec les 3 modèles. La Table 6 montre ces générations [5]. On observe une plus grande variété de mots prédits, comme des points ou des symboles de fin de génération (</s>). On remarque aussi que les points sont toujours suivis de symboles </s>, ce qui est normal car la base de données est une liste de phrase et non un grand texte. Cependant, on observe quand même les limites des 3 modèles sur la génération du fait du peu de sens de la phrase générée.

modèles	génération
FROZEN	le vieillard fit un , . </s>
SCRATCH	le vieillard fit un signe à la et . </s>
ADAPT	le vieillard fit un de , . </s>

TABLE 6 – Résultat des générations de 10 mots des modèles à partir de : *le vieillard fit un*, avec une température de 0.6

6 Conclusions et perspectives

Ce projet a permis d'explorer trois approches pour la création d'un modèle de langage basé sur des réseaux de neurones multi-couches. Les modèles *FROZEN*, *SCRATCH*, et *ADAPT* ont été développés et évalués en utilisant diverses métriques de performance.

Le modèle *FROZEN*, qui utilise des embeddings pré-appris de Word2Vec, a montré des résultats acceptables en termes d'accuracy, top-k, perplexité et f_1-score. Cependant, il a du mal à générer des séquences de texte cohérentes.

Le modèle *SCRATCH*, qui apprend à la fois les embeddings et le modèle de langage, a montré des performances inférieures en termes de perplexité et de Cross Entropy, ce qui suggère qu'il a plus de difficulté à prédire les mots. Les temps d'entraînement de ce modèle sont également significativement plus longs.

Le modèle *ADAPT*, qui initialise les embeddings à partir de Word2Vec et les ajuste pendant l'apprentissage, a montré des performances similaires au modèle

5. Attention, il faut noter que cette nouvelle méthode de génération est stochastique et que par conséquent, les résultats présentés ne sont qu'une génération possible parmi l'ensemble des générations.

FROZEN tout en bénéficiant de temps d'entraînement plus courts. Cela suggère que l'initialisation des embeddings avec Word2Vec peut être une approche efficace pour accélérer l'entraînement sans compromettre significativement les performances.

Les générations de texte à partir des modèles ont révélé des lacunes dans la capacité des modèles à produire des séquences de texte cohérentes. Cela indique la nécessité d'améliorations futures pour ces modèles.

En fin de compte, le choix entre les modèles dépendra des priorités de l'application, du temps d'entraînement disponible et des performances requises. Le modèle *ADAPT* semble être un compromis intéressant entre performance et temps d'entraînement.

Pour améliorer les performances des modèles de langage présentés, plusieurs approches peuvent être explorées. Tout d'abord, l'ajout de couches de récurrentes ou de réseaux de neurones récurrents (RNN) peut aider à capturer des dépendances temporelles plus complexes dans le texte, ce qui pourrait améliorer la cohérence des générations de texte. De plus, l'utilisation de techniques de régularisation, telles que le dropout pourrait contribuer à réduire le surajustement et à améliorer la généralisation des modèles. En outre, l'augmentation de la taille du corpus d'entraînement pourrait permettre aux modèles d'apprendre des représentations plus riches. Enfin, l'exploration de méthodes de génération de texte plus avancées et récentes, telles que les modèles de langage transformer,l'utilisation de mécanismes d'attention, peut être une piste prometteuse pour produire des textes plus cohérents et naturels. En combinant ces améliorations potentielles, il est possible d'obtenir des modèles de langage plus performants et capables de générer du texte de haute qualité.

Références

[1] T. Mikolov, K. Chen, G. Corrado et J. Dean, « Efficient estimation of word representations in vector space, » *arXiv preprint arXiv :1301.3781*, 2013.

[2] A. F. Agarap, « Deep Learning using Rectified Linear Units (ReLU), » *CoRR*, t. abs/1803.08375, 2018. arXiv : 1803.08375. adresse : http://arxiv.org/abs/1803.08375.

[3] D. P. Kingma et J. Ba, « Adam : A method for stochastic optimization, » *arXiv preprint arXiv :1412.6980*, 2014.

[4] L. Liu, T. G. Dietterich, N. Li et Z. Zhou, « Transductive Optimization of Top k Precision, » *CoRR*, t. abs/1510.05976, 2015. arXiv : 1510.05976. adresse : http://arxiv.org/abs/1510.05976.